

# 非线性最小二乘问题的算法介绍

## 引言

非线性最小二乘问题（Nonlinear Least Squares, NLS）在科学和工程领域具有广泛的应用，如曲线拟合、参数估计和机器学习等。与线性最小二乘问题相比，非线性最小二乘问题更为复杂，因为残差函数是参数的非线性函数，导致优化问题具有非凸性和多极值点的特征。

在本文中，我们将详细介绍非线性最小二乘问题的数学模型，分析其几何意义，并深入探讨经典的求解算法，如高斯-牛顿法和列文伯格-马夸尔特法。同时，我们将给出这些算法的收敛性定理和证明，并比较两种方法的优缺点。

## 基本思想

非线性最小二乘问题的目标是找到参数向量  $x \in \mathbb{R}^n$ ，使得非线性模型函数  $f(x)$  与观测数据  $y \in \mathbb{R}^m$  之间的差异最小化。具体地，我们定义残差向量  $r(x) = f(x) - y$ ，并构建目标函数：

$$\min_{x \in \mathbb{R}^n} F(x) = \frac{1}{2} \|r(x)\|^2 = \frac{1}{2} \sum_{i=1}^m [r_i(x)]^2.$$


由于  $r_i(x)$  通常是非线性函数，直接求解最优解  $x^*$  并不容易。为此，我们借助迭代优化算法，逐步逼近最优解。

## 几何解释

从几何角度来看，非线性最小二乘问题是寻找参数空间中的一点，使得由参数确定的模型曲面尽可能接近观测数据点。每个参数向量  $x$  对应一个模型曲面  $f(x)$ ，我们希望找到使得  $f(x)$  与  $y$  之间的欧氏距离最小的  $x^*$ 。

### 几何解释：

非线性最小二乘问题可以视为在高维空间中，将观测数据点  $y$  投影到模型曲面  $f(x)$  上的过程。通过调整参数  $x$ ，我们使得模型曲面在参数空间中移动，直到找到与数据点最接近的位置。



## 算法介绍

### 高斯-牛顿法

高斯-牛顿法是针对非线性最小二乘问题的一种有效迭代算法。其基本思想是在线性近似的基础上，将非线性问题转化为线性最小二乘问题。在第  $k$  次迭代中，我们对残差函数  $r(x)$  进行一阶泰勒展开：

$$r(x_k + \Delta x) \approx r(x_k) + J(x_k)\Delta x,$$

其中  $J(x_k) \in \mathbb{R}^{m \times n}$  是残差函数的雅可比矩阵，定义为：

$$[J(x_k)]_{ij} = \frac{\partial r_i}{\partial x_j} \Big|_{x=x_k}.$$

然后，令增量  $\Delta x$  最小化线性近似下的目标函数：

$$\min_{\Delta x} \frac{1}{2} \|r(x_k) + J(x_k)\Delta x\|^2.$$

求解上述问题的正规方程：

$$J(x_k)^T J(x_k) \Delta x = -J(x_k)^T r(x_k).$$

更新参数：

$$x_{k+1} = x_k + \Delta x.$$

### 列文伯格-马夸尔特法

高斯-牛顿法在残差函数较为线性时表现良好，但在非线性程度较高时可能会出现收敛困难。列文伯格-马夸尔特法 (Levenberg-Marquardt method) 通过引入阻尼因子，将高斯-牛顿法与梯度下降法结合，提高了算法的鲁棒性。

其更新公式为：

$$(J(x_k)^T J(x_k) + \lambda_k I) \Delta x = -J(x_k)^T r(x_k),$$

其中  $\lambda_k$  为阻尼因子， $I$  为单位矩阵。当  $\lambda_k$  较大时，更新方向接近于梯度下降方向；当  $\lambda_k$  较小时，更新方向接近于高斯-牛顿方向。

### 算法步骤

#### 算法 1：高斯-牛顿法

---

**Algorithm 1** Gauss-Newton Method

---

- 1: 初始化参数  $x_0$ ，设定容差  $\varepsilon > 0$ 。
  - 2: **for**  $k = 0, 1, 2, \dots$  **do**
  - 3:   计算残差  $r(x_k)$  和雅可比矩阵  $J(x_k)$ 。
  - 4:   求解线性方程组  $J(x_k)^T J(x_k) \Delta x = -J(x_k)^T r(x_k)$ 。
  - 5:   更新参数  $x_{k+1} = x_k + \Delta x$ 。
  - 6:   **if**  $\|\Delta x\| < \varepsilon$  **then**
  - 7:     停止迭代。
  - 8:   **end if**
  - 9: **end for**
-

## 算法 2: 列文伯格-马夸尔特法

**Algorithm 2** Levenberg-Marquardt Method

---

```

1: 初始化参数  $x_0$ , 阻尼因子  $\lambda_0 > 0$ , 设定容差  $\varepsilon > 0$ , 参数  $\nu > 1$ 。
2: for  $k = 0, 1, 2, \dots$  do
3:   计算残差  $r(x_k)$  和雅可比矩阵  $J(x_k)$ 。
4:   求解线性方程组  $(J(x_k)^T J(x_k) + \lambda_k I) \Delta x = -J(x_k)^T r(x_k)$ 。
5:   计算新的目标函数值  $F(x_k + \Delta x)$ 。
6:   if  $F(x_k + \Delta x) < F(x_k)$  then
7:     更新参数  $x_{k+1} = x_k + \Delta x$ 。
8:     令  $\lambda_{k+1} = \lambda_k / \nu$ 。
9:   else
10:    保持参数不变  $x_{k+1} = x_k$ 。
11:    令  $\lambda_{k+1} = \lambda_k \times \nu$ 。
12:   end if
13:   if  $\|\Delta x\| < \varepsilon$  then
14:     停止迭代。
15:   end if
16: end for

```

---

## 收敛性分析

## 高斯-牛顿法的收敛性

**定理 1** (高斯-牛顿法的局部收敛性). 设  $r(x)$  是关于  $x$  的二阶连续可微函数, 且在最优解  $x^*$  附近, 雅可比矩阵  $J(x)$  满秩. 若初始点  $x_0$  足够接近  $x^*$ , 则高斯-牛顿法产生的迭代序列  $\{x_k\}$  将以线性甚至二次速率收敛于  $x^*$ 。

证明. 由于  $r(x)$  二阶连续可微, 在  $x^*$  附近可进行二阶泰勒展开:

$$r(x) = r(x^*) + J(x^*)(x - x^*) + \frac{1}{2}H(x^*)(x - x^*)^2 + o(\|x - x^*\|^2),$$

其中  $H(x^*)$  为残差函数的二阶导数矩阵. 由于  $r(x^*) = 0$ , 代入高斯-牛顿法的更新公式, 可得:

$$x_{k+1} - x^* = (I - (J^T J)^{-1} J^T J)(x_k - x^*) + o(\|x_k - x^*\|).$$

由于  $J(x^*)$  满秩,  $J^T J$  是正定的, 故  $I - (J^T J)^{-1} J^T J = 0$ . 因此, 有:

$$x_{k+1} - x^* = o(\|x_k - x^*\|).$$

这表明算法具有至少线性收敛性, 若更进一步的条件满足, 可以达到二次收敛。 □

## 列文伯格-马夸尔特法的收敛性

**定理 2** (列文伯格-马夸尔特法的全局收敛性). 在适当的条件下, 列文伯格-马夸尔特法对非线性最小二乘问题具有全局收敛性, 即从任意初始点出发, 算法产生的迭代序列  $\{x_k\}$  至少收敛到一个局部最小点。

证明. 列文伯格-马夸尔特法通过调整阻尼因子  $\lambda_k$ , 保证每次迭代都使目标函数  $F(x)$  非增。当  $F(x_{k+1}) < F(x_k)$  时, 我们减小  $\lambda_k$ , 使得算法更倾向于高斯-牛顿方向, 加快收敛速度; 当  $F(x_{k+1}) \geq F(x_k)$  时, 我们增大  $\lambda_k$ , 使更新方向更接近于梯度方向, 增强稳定性。

由于目标函数  $F(x)$  有下界 (即非负), 且算法保证  $F(x)$  单调非增, 因此  $\{F(x_k)\}$  收敛。结合参数更新策略和步长控制, 可以证明算法的全局收敛性。□

## 方法比较

### 高斯-牛顿法与列文伯格-马夸尔特法的比较:

- 收敛速度:** 高斯-牛顿法在残差函数近似线性的情况下, 收敛速度较快, 可能达到二次收敛; 列文伯格-马夸尔特法由于引入了阻尼因子, 收敛速度可能略有降低。
- 鲁棒性:** 高斯-牛顿法对初始点和非线性程度较为敏感, 可能出现收敛困难; 列文伯格-马夸尔特法通过阻尼因子调整, 增强了算法的鲁棒性。
- 实现难度:** 高斯-牛顿法实现较为简单, 但需要求解可能病态的线性方程组; 列文伯格-马夸尔特法需要设置阻尼因子调整策略, 稍微复杂一些。

## 应用与案例分析

非线性最小二乘问题在实际中有诸多应用, 例如:

- 曲线拟合:** 通过调整模型参数, 使得曲线尽可能贴合实验数据。
- 参数估计:** 在统计学中, 利用最小二乘方法估计模型参数。
- 机器学习:** 在训练非线性模型 (如神经网络) 时, 最小化损失函数。

### 案例: 指数模型拟合

假设我们有一组数据点  $\{(t_i, y_i)\}$ , 希望拟合指数模型  $y = ae^{bt}$ , 其中  $a$  和  $b$  为待定参数。定义残差:

$$r_i(a, b) = ae^{bt_i} - y_i.$$

构建目标函数:

$$F(a, b) = \frac{1}{2} \sum_{i=1}^n [r_i(a, b)]^2.$$

利用列文伯格-马夸尔特法, 我们可以迭代求解参数  $a$  和  $b$ , 使得模型曲线最佳拟合数据。

## 总结

非线性最小二乘问题是优化领域的重要问题，在科学研究和工程实践中有着广泛的应用。通过对高斯-牛顿法和列文伯格-马奎尔特法的深入分析，我们了解了求解非线性最小二乘问题的有效方法。高斯-牛顿法利用线性近似，在残差函数较为线性的情况下具有快速的收敛速度。列文伯格-马奎尔特法通过引入阻尼因子，增强了算法的鲁棒性，能够适应更广泛的非线性问题。在实际应用中，合理选择初始参数、阻尼因子调整策略以及高效的数值计算方法，对于算法的成功实施至关重要。未来的研究可以进一步探讨更为复杂的非线性问题，以及在大规模数据和高维参数空间中的应用。