

# 近端梯度下降法 (Proximal Gradient Descent)

## 背景介绍

在许多优化问题中，目标函数包含光滑项和非光滑项。例如，稀疏回归中的  $\ell_1$  正则化项。传统的梯度下降法难以处理非光滑项，而近端梯度下降法通过结合梯度下降和近端算子的方法，有效解决了这一问题。这使得该方法在机器学习、信号处理等领域得到了广泛应用。

## 算法思想

近端梯度下降法旨在最小化如下形式的优化问题：

$$\min_{x \in \mathbb{R}^n} f(x) + g(x),$$

其中， $f(x)$  是可微的凸函数， $g(x)$  是凸但可能不可微的函数。该方法通过迭代地应用梯度下降步骤和近端算子，逐步逼近最优解。

**定义 1** (近端梯度下降法). 近端梯度下降法的迭代步骤为：

$$x_{k+1} = \text{prox}_{\alpha g}(x_k - \alpha \nabla f(x_k)),$$

其中， $\alpha > 0$  是步长， $\text{prox}_{\alpha g}$  是  $g$  的近端算子，定义为：

$$\text{prox}_{\alpha g}(v) = \arg \min_x \left( \frac{1}{2\alpha} \|x - v\|_2^2 + g(x) \right).$$

## 算法步骤

**定义 2** (近端梯度下降算法). 1. 初始化  $x_0 \in \mathbb{R}^n$ , 选择步长  $\alpha > 0$ .

2. 对于每次迭代  $k = 0, 1, 2, \dots$ , 执行:

(a) 计算梯度步:  $v_k = x_k - \alpha \nabla f(x_k)$ .

(b) 应用近端算子:  $x_{k+1} = \text{prox}_{\alpha g}(v_k)$ .

3. 重复步骤 2, 直到满足停止条件。

## 理解与几何意义

### 理解

近端梯度下降法结合了梯度下降和近端算子的优势。每次迭代中, 首先沿梯度方向进行一步下降, 以减少光滑部分的目标函数值; 然后通过近端算子调整步进结果, 以处理非光滑项。这种方法不仅保持了优化方向的有效性, 还能够引导解具备特定的结构性, 如稀疏性。

## 例子

**例子 1** (稀疏回归 (LASSO)). 考虑目标函数:

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1,$$

其中,  $f(x) = \frac{1}{2} \|Ax - b\|_2^2$ ,  $g(x) = \lambda \|x\|_1$ 。

近端梯度下降法的迭代步骤为:

$$x_{k+1} = \text{soft}(x_k - \alpha A^T(Ax_k - b), \alpha\lambda),$$

其中,  $\text{soft}$  为软阈值算子, 定义为:

$$\text{soft}(v, \tau) = \text{sign}(v) \cdot \max\{|v| - \tau, 0\}.$$

## 收敛性

**定理 1** (近端梯度下降法的收敛性). 假设  $f$  是  $L$ -Lipschitz 可微的凸函数, 且  $g$  是凸函数。当步长  $\alpha$  满足  $0 < \alpha < \frac{1}{L}$  时, 序列  $\{x_k\}$  收敛到最优解。

### 理解

由于  $f$  具有  $L$ -Lipschitz 连续梯度, 结合  $g$  的凸性, 每一步迭代都确保目标函数值不增加, 且序列  $\{x_k\}$  逐步逼近最优解。这保证了算法的收敛性。

## 几何解释

### 理解

近端算子的几何意义：

近端算子  $\text{prox}_{\alpha g}(v)$  可以看作是在点  $v$  处，对函数  $g$  加上一个二次罚项的最小化过程。这相当于在  $v$  附近寻找一个平衡点，使得  $x$  既接近  $v$ ，又在  $g(x)$  的约束下尽可能优化。

